



# FACT-AUDIT

Evidence-Augmented Adaptive Fact-Checking Audit

**Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn**

GVHD: TS. Lưu Thanh Sơn

IT2040 · Các mô hình ngôn ngữ lớn & ứng dụng · Báo cáo cuối kỳ

Ho Chi Minh, 07/2026



1. **Bối cảnh & động lực:** vì sao cần đánh giá fact-checking của LLM? · Tiến
2. **FACT-AUDIT framework:** 3 giai đoạn và Importance Sampling · Tiến
3. **Khung 5 agent** và cấu trúc test case · Quang
4. **Metrics & Kết quả:** IMR / JFR / Grade trên 13 LLM · Quang
5. **Thực nghiệm tái hiện:** nhóm chạy lại framework · Ấn
6. **Hướng mở rộng: RAG**, đề xuất của nhóm · Ấn

Đây là **framework đánh giá năng lực** fact-checking của LLM, không phải kiểm chứng một claim cụ thể.



# 1

---

## Bối cảnh & động lực

Vì sao cần đánh giá năng lực fact-checking của LLM?

Phần 1 · Trình bày: Tô Huỳnh Minh Tiến



**Fact-checking** = đưa mô hình một phát biểu, nó phải làm 2 việc:


- **Phán:** phát biểu là Đúng / Sai / Chưa đủ thông tin
- **Giải thích:** nêu lý do cho phán quyết đó (**justification**)

LLM nhớ rất nhiều kiến thức nên làm khá tốt, nhưng vẫn **nhớ sai** và **suy luận sai**.

**Câu hỏi của bài báo:** Làm sao **tự động chấm điểm** năng lực fact-checking của một LLM một cách công bằng, để biết mô hình nào thật sự đáng tin?

- **Gán nhãn thủ công:** tốn kém, khó mở rộng quy mô
- **Dataset tĩnh:** test data leakage, leaderboard swamping
- **Chỉ đo accuracy của verdict:** bỏ qua justification

Về bản chất, đây là một paradigm phân loại tĩnh: không đánh giá được lập luận và không theo kịp các LLM mới.



Pipeline đánh giá cũ (a) vs FACT-AUDIT (b) – Lin et al., Fig 1

**Verdict đúng ≠ Lập luận đúng:** mô hình có thể dự đoán đúng nhãn nhưng lập luận sai hoặc thiếu cơ sở.



# 2

---

## FACT-AUDIT framework

3 giai đoạn lặp · Importance Sampling nhắm điểm yếu

Phần 2 · Trình bày: Tô Huỳnh Minh Tiến



## 2 đặc trưng mới

- Test data **cập nhật động**
- Đánh giá sâu **justification**, không chỉ verdict

Hướng tiếp cận: **agent-driven**, **model-centric**, tự thích nghi theo từng target LLM.


## Monte Carlo → Importance Sampling

$$\mathbb{E}_{p(x)}[F_\alpha(x)] = \int p(x) F_\alpha(x) dx$$

MC chậm  $O(1/\sqrt{N})$  → dùng  $q(x)$  nhắm vùng LLM **dễ sai**:

$$\mathbb{E}_{q(x)}\left[F_\alpha(x) \frac{p(x)}{q(x)}\right]$$

$F_\alpha(x)$  = giới hạn hiểu biết của LLM trên case  $x$ ; chọn  $q(x) \propto p(x) F_\alpha(x)$  để lấy mẫu hiệu quả.



$\Theta_{i+1} \sim \pi(\Theta_{i+1} \mid \Theta_i, M)$ : mỗi vòng tập trung vào **điểm yếu** của target LLM. 3 đối tượng khởi tạo: Complex Claim · Fake News · Social Rumor.





# 3

---


## Khung 5 agent & test case

5 vai trò agent · taxonomy kịch bản · cấu trúc test case

Phần 3 · Trình bày: Trần Tú Quang

- **Appraiser (stage 1 & 3)**: xây & cập nhật **taxonomy** kịch bản
- **Inquirer (1)**: sinh **prototype test data**
- **Quality Inspector (1)**: kiểm **chất lượng & đa dạng**, validate evidence (Wiki API)
- **Evaluator (2)**: **LLM-as-a-Judge**, chấm **Grade 1-10**, lưu **Memory Pool**  $M = \{x, r, s, c\}$
- **Prober (2)**: **probing lặp** từ  $M \rightarrow$  sinh case khó hơn

**Memory Pool**  $M = \{x, r, s, c\}$ : test case, response, score, comment · nhật ký nối Evaluator với Prober.





*Appraiser khởi tạo cây kịch bản từ 3 nhóm, mở rộng dần qua các vòng lặp (Lin et al., Fig 3).*



## 4 thành phần

- **Key Point:** chỉ dẫn nhiệm vụ
- **Source Claim:** câu cần kiểm chứng
- **Auxiliary Info:** bằng chứng phụ trợ
- **Test Mode:** bối cảnh bài toán

## 3 Test Mode

- `[claim]` : **không** evidence (closed-book)
- `[evidence]` : bằng chứng vàng từ Wiki
- `[wisdom of crowds]` : luồng bình luận MXH

Test Mode chính là chỗ **RAG** sẽ tác động.



# 4

---

## Metrics & Kết quả

IMR · JFR · Grade — đánh giá trên 13 LLM

Phần 4 · Trình bày: Trần Tú Quang



| Metric                              | Ý nghĩa                                                                                                       | Tốt khi          |
|-------------------------------------|---------------------------------------------------------------------------------------------------------------|------------------|
| IMR: <b>Insight Mastery Rate</b>    | Tỉ lệ số câu bị chấm <b>Grade <math>\leq 3/10</math></b> (tức trả lời có lỗi). <b>Chỉ số chính.</b>           | <b>càng thấp</b> |
| JFR: <b>Justification Flaw Rate</b> | Tỉ lệ số câu <b>đoán đúng nhãn nhưng lập luận sai/rỗng</b>                                                    | <b>càng thấp</b> |
| Grade                               | Điểm giám khảo (Evaluator) chấm <b>1–10</b> . Bị <b><math>\leq 3</math></b> nếu sai nhãn <b>hoặc</b> lập luận | <b>càng cao</b>  |

**Vì sao cần JFR?** Nó bắt được ca "đoán trúng nhãn nhưng lập luận rỗng", điều mà cách chỉ đo đúng/sai nhãn thông thường bỏ sót.




| Model (Target LLM) | Complex Claim |             |             | Fake News    |             |             | Social Rumor |             |             | Overall      |             |             |
|--------------------|---------------|-------------|-------------|--------------|-------------|-------------|--------------|-------------|-------------|--------------|-------------|-------------|
|                    | IMR↓          | JFR↓        | Grade↑      | IMR↓         | JFR↓        | Grade↑      | IMR↓         | JFR↓        | Grade↑      | IMR↓         | JFR↓        | Grade↑      |
| Mistral-7B         | 60.21         | 25.62       | 3.98        | 47.50        | 19.58       | 4.87        | 59.05        | 39.52       | 3.97        | 54.79        | 23.34       | 4.34        |
| Llama2-7B          | 46.67         | 19.79       | 4.85        | 32.73        | 18.18       | 5.54        | 62.86        | 26.67       | 3.89        | 45.49        | 20.68       | 4.88        |
| Llama2-13B         | 65.67         | 21.66       | 3.71        | 55.33        | 16.67       | 4.42        | 48.10        | 20.48       | 4.78        | 57.28        | 19.50       | 4.25        |
| Llama3-8B          | 39.79         | 12.09       | 5.19        | 33.75        | 17.28       | 5.51        | 46.25        | 19.18       | 4.83        | 38.67        | 15.60       | 5.25        |
| Llama3.1-8B        | 55.83         | 21.46       | 4.36        | 36.39        | 12.78       | 5.60        | 47.62        | 12.86       | 5.00        | 47.52        | 16.77       | 4.91        |
| Llama3.1-70B       | 41.56         | 14.22       | 5.34        | 25.00        | 11.88       | 6.42        | 38.33        | 10.00       | 5.55        | 34.10        | 12.38       | 5.83        |
| Qwen2.5-7B         | 38.97         | 9.74        | 5.38        | 21.54        | 8.20        | 6.58        | 36.67        | 5.42        | 5.68        | 31.76        | 8.14        | 5.91        |
| Qwen2.5-72B        | <u>22.08</u>  | <u>5.41</u> | <u>6.62</u> | <b>10.42</b> | <b>1.46</b> | <b>7.67</b> | <u>15.00</u> | 3.75        | 7.28        | <u>16.00</u> | <b>3.50</b> | <u>7.17</u> |
| GLM4-9B            | 52.73         | 16.36       | 4.76        | 51.67        | 14.00       | 4.93        | 50.00        | 15.24       | 5.00        | 51.67        | 15.24       | 4.88        |
| Gemma2-9B          | 41.67         | 28.00       | 4.84        | 35.48        | 28.11       | 5.13        | 44.07        | 23.31       | 4.74        | 39.70        | 26.78       | 4.94        |
| Gemini-Pro         | 30.21         | 11.87       | 5.98        | 19.39        | 5.76        | 6.59        | 32.86        | 5.72        | 5.78        | 27.25        | 8.62        | 6.14        |
| Claude3.5-Sonnet   | 32.71         | 9.37        | 6.16        | 15.00        | <u>2.33</u> | <u>7.41</u> | 18.57        | <u>3.33</u> | <u>7.31</u> | 24.34        | 5.96        | 6.78        |
| GPT-4o             | <b>14.05</b>  | <b>4.34</b> | <b>6.78</b> | <u>10.56</u> | 4.93        | 7.26        | <b>10.48</b> | <b>1.41</b> | <b>7.62</b> | <b>12.02</b> | <u>3.55</u> | <b>7.21</b> |

GPT-4o đạt IMR thấp nhất (12.02%); Qwen2.5-72B (mã nguồn mở) bám sát. IMR là metric chủ đạo – Lin et al., Table 1.


Setup: 13 LLM = 10 open-source + 3 proprietary · suy luận zero-shot · temperature = 0 (tái lập được). Human và LLM tạo prototype cho IMR tương đương (Table 2).

## Kịch bản khó nhất



IMR của 2 kịch bản khó nhất mỗi nhóm (Fig 4)

## Vòng lặp hội tụ



IMR giảm dần & hội tụ qua các vòng probing (Fig 5)





| Test Mode          | Độ khó     | GPT-4o IMR   | Ảnh xạ RAG                       |
|--------------------|------------|--------------|----------------------------------|
| [claim]            | Khó nhất   | 23.1%        | RAG tắt · <b>baseline</b>        |
| [wisdom of crowds] | Trung bình | 15.4%        | evidence nhiều                   |
| [evidence]         | Dễ nhất    | <b>10.6%</b> | retrieval hoàn hảo · <b>trần</b> |

**Có bằng chứng giúp LLM fact-check chính xác hơn đáng kể** (IMR giảm khoảng 2 lần). 3 mode = phổ chất lượng evidence: [claim] là **baseline** (chưa RAG), [evidence] là **trần trần** (RAG lý tưởng); RAG thực tế nằm giữa, tùy chất lượng retriever.



5

---

# Thực nghiệm tái hiện

Nhóm chạy lại framework: baseline · vòng lặp adaptive · so sánh model

Phần 5 · Trình bày: Nguyễn Ấn



## Phân vai 3 agent (qua API)

- **Optimizer:** `gemini-2.5-flash`
- **Judge:** `gemini-2.5-flash`
- **Target (model bị test):** thay đổi

## Giữ nguyên logic paper

- Chỉ đổi backend LLM sang API
- Importance Sampling & taxonomy: nguyên vẹn

## Quy mô mỗi lần chạy

- 3 seed (**Monte Carlo**) + 7 adaptive (**Importance Sampling**)
- Nhóm kịch bản: `complex_claim`
- Metric: **Grade 1–10, IMR** (% Grade  $\leq 3$ )

Mục tiêu mid-term: chứng minh **tái hiện đúng cơ chế** của paper, không phải đạt SOTA.



**Chạy target LLaMA-4-Scout:** seed case chế độ `wisdom of crowds` bị điểm thấp (3/10).

Ở 7 case adaptive tiếp theo, Optimizer sinh **6/7 case đều** `wisdom of crowds` – đúng chế độ mô hình vừa làm kém. Đây chính là  $q(x)$  tự dồn mật độ vào vùng  $F_\alpha(x)$  thấp.

**Tái hiện 2 tầng adaptive:**

- **Tầng 1 (Prober):** sinh case khó hơn TRONG một kịch bản
- **Tầng 2 (Appraiser):** phân tích bad case → sinh **kịch bản MỚI** `deductive_causal_reasoning` (suy luận nhân quả nhiều bước) mà taxonomy gốc chưa có

| Target model          | Grade       | IMR (% Grade $\leq 3$ ) |
|-----------------------|-------------|-------------------------|
| LLaMA-4-Scout-17B     | 8.00        | 20%                     |
| <b>Gemini 2.5 Pro</b> | <b>9.80</b> | <b>0%</b>               |

Model mạnh (Gemini Pro) có **IMR thấp hơn hẳn**: khớp tinh thần Table 1 của paper (IMR là chỉ số phân biệt năng lực).

Model càng mạnh, Importance Sampling càng **khó đào ra điểm yếu** → cần nhiều vòng probing hơn để hội tụ (khớp Fig 5).



---

# Từ Limitation → RAG

Đề xuất mở rộng của nhóm: cấp evidence qua retriever

Phần 6 · Trình bày: Nguyễn Ấn



## 1. Định kiến tiềm ẩn (bias)

Agent controller (GPT-4o) mang định kiến tri thức riêng.

VD: model có thể ưu tiên nguồn tiếng Anh, bỏ sót context văn hoá khác.

## 2. Tri thức tĩnh, không cập nhật động

Agent chỉ dùng tri thức đã học lúc train.

VD: claim về sự kiện mới sau training cutoff, model không có evidence để đối chiếu.


## 3. Thiếu cơ chế cải thiện mô hình

Framework chỉ kiểm định, chưa giúp model học lại.

VD: phát hiện LLaMA yếu ở "multi-step reasoning" nhưng không có bước fine-tune khắc phục.

Nhóm khai thác **hạn chế (2)**: paper tự đề xuất RAG, Table 3 cho thấy [evidence] dễ hơn [claim] rõ rệt, đủ cơ sở để thử nghiệm.

Paper tự nêu: "...incorporate advanced techniques such as Retrieval-Augmented Generation (RAG)..."



Giả thuyết: việc bổ sung evidence đưa trường hợp `[claim]` tiệm cận `[evidence]`, kỳ vọng giảm IMR/JFR (trên cùng claim set và cùng target model).

**Câu hỏi để ngỏ cho final-term:** evidence của paper là **gold** (chuẩn, do người soạn). RAG thực tế lấy evidence **tự động** – nếu retrieval **kém liên quan** thì IMR có giảm không? Kết quả so sánh baseline vs RAG sẽ trình bày ở báo cáo cuối kỳ.





## Đã làm được

- Hiểu & trình bày cơ chế FACT-AUDIT
- Tái hiện framework qua API
- Xác nhận Importance Sampling nhằm điểm yếu
- Tái hiện 2 tầng adaptive
- So sánh model: framework phân biệt mạnh/yếu

## Hướng final-term

- Cắm retriever (RAG) trước target
- So sánh baseline vs RAG trên cùng claim set
- Phân tích ảnh hưởng của **chất lượng retrieval** lên IMR/JFR

Cốt lõi: từ **hiểu paper** → **tái hiện được** → **đề xuất mở rộng có cơ sở**.



# Cảm ơn! · Q&A

**Nhóm 15 · IT2040**

Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn

Lin et al., **FACT-AUDIT**, ACL 2025 · arXiv 2502.17924

University of Information Technology, VNU-HCM (UIT)