



FACT-AUDIT + RAG

Evidence-Augmented Adaptive Fact-Checking Audit

Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn

GVHD: TS. Lưu Thanh Sơn

IT2040 · Các mô hình ngôn ngữ lớn & ứng dụng · Báo cáo cuối kỳ

Ho Chi Minh, 7/2026



1. **Bối cảnh & động lực:** vì sao cần đánh giá fact-checking của LLM?
2. **FACT-AUDIT framework:** 3 giai đoạn + Importance Sampling
3. **Khung 5 agent** + cấu trúc test case
4. **Metrics & Kết quả:** IMR / JFR / Grade trên 13 LLM
5. **Từ Limitation → RAG:** đề xuất mở rộng của nhóm

Đây là **framework đánh giá năng lực** fact-checking của LLM, không phải kiểm chứng một claim cụ thể.



Cho một **Source Claim**, fact-checking dự đoán tính đúng sai **kèm lập luận**, gán nhãn **Factual / Non-Factual / Not Enough Info** dựa trên tri thức phụ trợ.

LLM lưu tri thức như "knowledge base" → hỗ trợ fact-checking, nhưng vẫn **sai kiến thức** và **lỗi suy luận**.

Câu hỏi nghiên cứu: Làm sao **đánh giá tự động & có hệ thống** giới hạn năng lực fact-checking của LLM, để biết model nào đáng tin?



#	Hạn chế của eval cũ	Hệ quả
1	Annotation thủ công	Tốn kém, khó scale
2	Dataset tĩnh	Test data leakage + leaderboard swamping
3	Chỉ đo accuracy của verdict	Bỏ qua justification (lập luận)

Verdict đúng $\neq$ Lập luận đúng: model có thể đoán trúng nhãn nhưng lý do sai/rỗng.



2 đặc trưng mới

- Test data **cập nhật động**
- Đánh giá sâu **justification**, không chỉ verdict

→ **agent-driven**, **model-centric**, tự thích nghi theo từng target LLM.


Monte Carlo → Importance Sampling

$$\mathbb{E}_{p(x)}[F_{\alpha}(x)] = \int p(x) F_{\alpha}(x) dx$$

MC chậm $O(1/\sqrt{N})$ → dùng $q(x)$ nhắm vùng LLM **dễ sai**:

$$\mathbb{E}_{q(x)}\left[F_{\alpha}(x) \frac{p(x)}{q(x)}\right]$$

$F_{\alpha}(x)$ = giới hạn hiểu biết của LLM trên case x ; chọn $q(x) \propto p(x) F_{\alpha}(x)$ để lấy mẫu hiệu quả.



$\Theta_{i+1} \sim \pi(\Theta_{i+1} \mid \Theta_i, M)$: mỗi vòng tập trung vào **điểm yếu** của target LLM. 3 đối tượng khởi tạo: Complex Claim · Fake News · Social Rumor.



Agent	Stage	Vai trò
Appraiser	1 & 3	Xây & cập nhật taxonomy kịch bản
Inquirer	1	Sinh prototype test data
Quality Inspector	1	Kiểm chất lượng & đa dạng , validate evidence (Wiki API)
Evaluator	2	LLM-as-a-Judge : chấm Grade 1–10 + comment, lưu M
Prober	2	Probing lặp từ $M \rightarrow$ sinh case khó hơn

Memory Pool $M = \{x, r, s, c\}$ · giới hạn năng lực $F_\alpha(x) \propto 1/s$.



4 thành phần

- **Key Point:** chỉ dẫn nhiệm vụ
- **Source Claim:** câu cần kiểm chứng
- **Auxiliary Info:** bằng chứng phụ trợ
- **Test Mode:** bối cảnh bài toán

Test Mode chính là chỗ ****RAG**** sẽ tác động.

3 Test Mode

- `[claim]`: **không** evidence (closed-book)
- `[evidence]`: bằng chứng vàng từ Wiki
- `[wisdom of crowds]`: luồng bình luận MXH



Metric	Nghĩa	Tốt
IMR: <i>Insight Mastery Rate</i>	% câu Grade ≤ 3 (có lỗi), <i>metric chủ đạo</i>	↓
JFR: <i>Justification Flaw Rate</i>	% case verdict đúng nhưng lập luận kém	↓
Grade	Điểm Evaluator 1–10 (≤ 3 nếu sai verdict <i>hoặc</i> justification)	↑

JFR tách được "đoán đúng nhãn nhưng lập luận rỗng", đúng tinh thần **verdict** $\neq$ **justification**.



Overall IMR ↓ (thấp = tốt)

Model	IMR
 GPT-4o	12.0%
 Qwen2.5-72B	16.0%
 Claude3.5-Sonnet	24.3%
Gemini-Pro	27.3%
Mistral-7B	54.8%

Nhận xét

- Top tier: GPT-4o, Qwen2.5-72B, Claude3.5, Gemini-Pro
- **Qwen2.5-72B** (open) ngang nhóm proprietary
- Dòng **LLaMA** yếu hơn rõ rệt
- Probing lặp → IMR **giảm dần & hội tụ**




Test Mode	Độ khó	GPT-4o IMR
[claim] (không bằng chứng)	Khó nhất	23.1%
[wisdom of crowds]	Trung bình	15.4%
[evidence] (có bằng chứng)	Dễ nhất	10.6%

Có bằng chứng → LLM fact-check tốt hơn hẳn (IMR giảm $\sim 2\times$). Đây là cánh cửa để RAG chen vào.



Paper tự nêu ở Limitations: "...incorporate advanced techniques such as Retrieval-Augmented Generation (RAG)..."



Giả thuyết: RAG kéo case `[claim]` → gần `[evidence]` ⇒ giảm IMR/JFR (cùng claim set, cùng target model).



Cảm ơn! · Q&A

Nhóm 8 · IT2040

Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn

Lin et al., [FACT-AUDIT](#), ACL 2025 · arXiv 2502.17924

University of Information Technology, VNU-HCM (UIT)