



FACT-AUDIT + RAG

Evidence-Augmented Adaptive Fact-Checking Audit

Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn

GVHD: TS. Lưu Thanh Sơn

IT2040 · Các mô hình ngôn ngữ lớn & ứng dụng · Báo cáo cuối kỳ

Ho Chi Minh, 07/2026



1. **Bối cảnh & động lực:** vì sao cần đánh giá fact-checking của LLM?
2. **FACT-AUDIT framework:** 3 giai đoạn và Importance Sampling
3. **Khung 5 agent** và cấu trúc test case
4. **Metrics & Kết quả:** IMR / JFR / Grade trên 13 LLM
5. **Từ Limitation → RAG:** đề xuất mở rộng của nhóm

Đây là **framework đánh giá năng lực** fact-checking của LLM, không phải kiểm chứng một claim cụ thể.



1

Bối cảnh & động lực

Vì sao cần đánh giá năng lực fact-checking của LLM?

Phần 1



Fact-checking = đưa mô hình một phát biểu, nó phải làm 2 việc:


- **Phán:** phát biểu là Đúng / Sai / Chưa đủ thông tin
- **Giải thích:** nêu lý do cho phán quyết đó (**justification**)

LLM nhớ rất nhiều kiến thức nên làm khá tốt, nhưng vẫn **nhớ sai** và **suy luận sai**.

Câu hỏi của bài báo: Làm sao **tự động chấm điểm** năng lực fact-checking của một LLM một cách công bằng, để biết mô hình nào thật sự đáng tin?

- **Gán nhãn thủ công:** tốn kém, khó mở rộng quy mô
- **Dataset tĩnh:** test data leakage, leaderboard swamping
- **Chỉ đo accuracy của verdict:** bỏ qua justification

Về bản chất, đây là một paradigm phân loại tĩnh: không đánh giá được lập luận và không theo kịp các LLM mới.



Pipeline đánh giá cũ (a) vs FACT-AUDIT (b) – Lin et al., Fig 1

Verdict đúng ≠ Lập luận đúng: mô hình có thể dự đoán đúng nhãn nhưng lập luận sai hoặc thiếu cơ sở.



2

FACT-AUDIT framework

3 giai đoạn lặp · Importance Sampling nhắm điểm yếu

Phần 2



2 đặc trưng mới

- Test data **cập nhật động**
- Đánh giá sâu **justification**, không chỉ verdict

Hướng tiếp cận: **agent-driven**, **model-centric**, tự thích nghi theo từng target LLM.


Monte Carlo → Importance Sampling

$$\mathbb{E}_{p(x)}[F_{\alpha}(x)] = \int p(x)F_{\alpha}(x) dx$$

MC chậm $O(1/\sqrt{N})$ → dùng $q(x)$ nhắm vùng LLM **dễ sai**:

$$\mathbb{E}_{q(x)}\left[F_{\alpha}(x) \frac{p(x)}{q(x)}\right]$$

$F_{\alpha}(x)$ = giới hạn hiểu biết của LLM trên case x ; chọn $q(x) \propto p(x)F_{\alpha}(x)$ để lấy mẫu hiệu quả.



$\Theta_{i+1} \sim \pi(\Theta_{i+1} \mid \Theta_i, M)$: mỗi vòng tập trung vào **điểm yếu** của target LLM. 3 đối tượng khởi tạo: Complex Claim · Fake News · Social Rumor.




3

Khung 5 agent & test case

5 vai trò agent · taxonomy kịch bản · cấu trúc test case

Phần 3

- **Appraiser (stage 1 & 3)**: xây & cập nhật **taxonomy** kịch bản
- **Inquirer (1)**: sinh **prototype test data**
- **Quality Inspector (1)**: kiểm **chất lượng & đa dạng**, validate evidence (Wiki API)
- **Evaluator (2)**: **LLM-as-a-Judge**, chấm **Grade 1-10**, lưu M
- **Prober (2)**: **probing lặp** từ $M \rightarrow$ sinh case khó hơn





Appraiser khởi tạo cây kịch bản từ 3 nhóm, mở rộng dần qua các vòng lặp (Lin et al., Fig 3).



4 thành phần

- **Key Point:** chỉ dẫn nhiệm vụ
- **Source Claim:** câu cần kiểm chứng
- **Auxiliary Info:** bằng chứng phụ trợ
- **Test Mode:** bối cảnh bài toán

3 Test Mode

- `[claim]` : **không** evidence (closed-book)
- `[evidence]` : bằng chứng vàng từ Wiki
- `[wisdom of crowds]` : luồng bình luận MXH

Test Mode chính là chỗ **RAG** sẽ tác động.



4

Metrics & Kết quả

IMR · JFR · Grade — đánh giá trên 13 LLM

Phần 4



Metric	Nghĩa	Tốt
IMR: Insight Mastery Rate	% câu Grade ≤ 3 (có lỗi), metric chủ đạo	↓
JFR: Justification Flaw Rate	% case verdict đúng nhưng lập luận kém	↓
Grade	Điểm Evaluator 1–10 (≤ 3 nếu sai verdict hoặc justification)	↑


JFR tách được "đoán đúng nhãn nhưng lập luận rỗng", đúng tinh thần **verdict $\neq$ justification**.



Model (Target LLM)	Complex Claim			Fake News			Social Rumor			Overall		
	IMR↓	JFR↓	Grade↑	IMR↓	JFR↓	Grade↑	IMR↓	JFR↓	Grade↑	IMR↓	JFR↓	Grade↑
Mistral-7B	60.21	25.62	3.98	47.50	19.58	4.87	59.05	39.52	3.97	54.79	23.34	4.34
Llama2-7B	46.67	19.79	4.85	32.73	18.18	5.54	62.86	26.67	3.89	45.49	20.68	4.88
Llama2-13B	65.67	21.66	3.71	55.33	16.67	4.42	48.10	20.48	4.78	57.28	19.50	4.25
Llama3-8B	39.79	12.09	5.19	33.75	17.28	5.51	46.25	19.18	4.83	38.67	15.60	5.25
Llama3.1-8B	55.83	21.46	4.36	36.39	12.78	5.60	47.62	12.86	5.00	47.52	16.77	4.91
Llama3.1-70B	41.56	14.22	5.34	25.00	11.88	6.42	38.33	10.00	5.55	34.10	12.38	5.83
Qwen2.5-7B	38.97	9.74	5.38	21.54	8.20	6.58	36.67	5.42	5.68	31.76	8.14	5.91
Qwen2.5-72B	<u>22.08</u>	<u>5.41</u>	<u>6.62</u>	10.42	1.46	7.67	<u>15.00</u>	3.75	7.28	<u>16.00</u>	3.50	<u>7.17</u>
GLM4-9B	52.73	16.36	4.76	51.67	14.00	4.93	50.00	15.24	5.00	51.67	15.24	4.88
Gemma2-9B	41.67	28.00	4.84	35.48	28.11	5.13	44.07	23.31	4.74	39.70	26.78	4.94
Gemini-Pro	30.21	11.87	5.98	19.39	5.76	6.59	32.86	5.72	5.78	27.25	8.62	6.14
Claude3.5-Sonnet	32.71	9.37	6.16	15.00	<u>2.33</u>	<u>7.41</u>	18.57	<u>3.33</u>	<u>7.31</u>	24.34	5.96	6.78
GPT-4o	14.05	4.34	6.78	<u>10.56</u>	4.93	7.26	10.48	1.41	7.62	12.02	<u>3.55</u>	7.21


GPT-4o đạt IMR thấp nhất (12.02%); Qwen2.5-72B (mã nguồn mở) bám sát. IMR là metric chủ đạo – Lin et al., Table 1.

Kịch bản khó nhất



IMR của 2 kịch bản khó nhất mỗi nhóm (Fig 4)

Vòng lặp hội tụ



IMR giảm dần & hội tụ qua các vòng probing (Fig 5)



Test Mode	Độ khó	GPT-4o IMR
[claim] (không bằng chứng)	Khó nhất	23.1%
[wisdom of crowds]	Trung bình	15.4%
[evidence] (có bằng chứng)	Dễ nhất	10.6%

Có bằng chứng giúp LLM fact-check chính xác hơn đáng kể (IMR giảm khoảng 2 lần). Đây là cơ sở để tích hợp RAG.




5

Từ Limitation → RAG

Đề xuất mở rộng của nhóm: cấp evidence qua retriever

Phần 5

Paper tự nêu ở **Limitations**: "...incorporate advanced techniques such as **Retrieval-Augmented Generation (RAG)**..."



Giả thuyết: việc bổ sung evidence đưa trường hợp `[claim]` tiệm cận `[evidence]`, kỳ vọng giảm IMR/JFR (trên cùng claim set và cùng target model).



Cảm ơn! · Q&A

Nhóm 8 · IT2040

Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn
Lin et al., **FACT-AUDIT**, ACL 2025 · arXiv 2502.17924

University of Information Technology, VNU-HCM (UIT)