



FACT-AUDIT

Evidence-Augmented Adaptive Fact-Checking Audit

Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn

GVHD: TS. Lưu Thanh Sơn

IT2040 · Các mô hình ngôn ngữ lớn & ứng dụng · Báo cáo cuối kỳ

Ho Chi Minh, 07/2026



1. **Bối cảnh & động lực:** vì sao cần đánh giá fact-checking của LLM? · Tiến
2. **FACT-AUDIT framework:** 3 giai đoạn và Importance Sampling · Tiến
3. **Khung 5 agent** và cấu trúc test case · Quang
4. **Metrics & Kết quả:** IMR / JFR / Grade trên 13 LLM · Quang
5. **Thực nghiệm tái hiện:** nhóm chạy lại framework · Ấn
6. **Hướng mở rộng: RAG**, đề xuất của nhóm · Ấn

Đây là **framework đánh giá năng lực** fact-checking của LLM, không phải kiểm chứng một claim cụ thể.



1

Bối cảnh & động lực

Vì sao cần đánh giá năng lực fact-checking của LLM?

Phần 1



Fact-checking = đưa mô hình một phát biểu, nó phải làm 2 việc:


- **Phán:** phát biểu là Đúng / Sai / Chưa đủ thông tin
- **Giải thích:** nêu lý do cho phán quyết đó (**justification**)

LLM nhớ rất nhiều kiến thức nên làm khá tốt, nhưng vẫn **nhớ sai** và **suy luận sai**.

Câu hỏi của bài báo: Làm sao **tự động chấm điểm** năng lực fact-checking của một LLM một cách công bằng, để biết mô hình nào thật sự đáng tin?

- **Gán nhãn thủ công:** tốn kém, khó mở rộng quy mô
- **Dataset tĩnh:** test data leakage, leaderboard swamping
- **Chỉ đo accuracy của verdict:** bỏ qua justification

Về bản chất, đây là một paradigm phân loại tĩnh: không đánh giá được lập luận và không theo kịp các LLM mới.



Pipeline đánh giá cũ (a) vs FACT-AUDIT (b) – Lin et al., Fig 1

Verdict đúng ≠ Lập luận đúng: mô hình có thể dự đoán đúng nhãn nhưng lập luận sai hoặc thiếu cơ sở.



2

FACT-AUDIT framework

3 giai đoạn lặp · Importance Sampling nhắm điểm yếu

Phần 2



2 đặc trưng mới

- Test data **cập nhật động**
- Đánh giá sâu **justification**, không chỉ verdict

Hướng tiếp cận: **agent-driven**, **model-centric**, tự thích nghi theo từng target LLM.


Monte Carlo → Importance Sampling

$$\mathbb{E}_{p(x)}[F_{\alpha}(x)] = \int p(x)F_{\alpha}(x) dx$$

MC chậm $O(1/\sqrt{N})$ → dùng $q(x)$ nhắm vùng LLM **dễ sai**:

$$\mathbb{E}_{q(x)}\left[F_{\alpha}(x) \frac{p(x)}{q(x)}\right]$$

$F_{\alpha}(x)$ = giới hạn hiểu biết của LLM trên case x ; chọn $q(x) \propto p(x)F_{\alpha}(x)$ để lấy mẫu hiệu quả.



$\Theta_{i+1} \sim \pi(\Theta_{i+1} \mid \Theta_i, M)$: mỗi vòng tập trung vào **điểm yếu** của target LLM. 3 đối tượng khởi tạo: Complex Claim · Fake News · Social Rumor.



3


Khung 5 agent & test case

5 vai trò agent · taxonomy kịch bản · cấu trúc test case

Phần 3

- **Appraiser (stage 1 & 3)**: xây & cập nhật **taxonomy** kịch bản
- **Inquirer (1)**: sinh **prototype test data**
- **Quality Inspector (1)**: kiểm **chất lượng & đa dạng**, validate evidence (Wiki API)
- **Evaluator (2)**: **LLM-as-a-Judge**, chấm **Grade 1-10**, lưu **Memory Pool** $M = \{x, r, s, c\}$
- **Prober (2)**: **probing lặp** từ $M \rightarrow$ sinh case khó hơn

Memory Pool $M = \{x, r, s, c\}$: test case, response, score, comment · nhật ký nối Evaluator với Prober.





Appraiser khởi tạo cây kịch bản từ 3 nhóm, mở rộng dần qua các vòng lặp (Lin et al., Fig 3).



4 thành phần

- **Key Point:** chỉ dẫn nhiệm vụ
- **Source Claim:** câu cần kiểm chứng
- **Auxiliary Info:** bằng chứng phụ trợ
- **Test Mode:** bối cảnh bài toán

3 Test Mode

- `[claim]` : **không** evidence (closed-book)
- `[evidence]` : bằng chứng vàng từ Wiki
- `[wisdom of crowds]` : luồng bình luận MXH

Test Mode chính là chỗ **RAG** sẽ tác động.



4

Metrics & Kết quả

IMR · JFR · Grade — đánh giá trên 13 LLM

Phần 4



Metric	Ý nghĩa	Tốt khi
IMR: Insight Mastery Rate	Tỉ lệ số câu bị chấm Grade $\leq 3/10$ (tức trả lời có lỗi). Chỉ số chính.	càng thấp
JFR: Justification Flaw Rate	Tỉ lệ số câu đoán đúng nhãn nhưng lập luận sai/rỗng	càng thấp
Grade	Điểm giám khảo (Evaluator) chấm 1–10 . Bị ≤ 3 nếu sai nhãn hoặc lập luận	càng cao

Vì sao cần JFR? Nó bắt được ca "đoán trúng nhãn nhưng lập luận rỗng", điều mà cách chỉ đo đúng/sai nhãn thông thường bỏ sót.




Model (Target LLM)	Complex Claim			Fake News			Social Rumor			Overall		
	IMR↓	JFR↓	Grade↑	IMR↓	JFR↓	Grade↑	IMR↓	JFR↓	Grade↑	IMR↓	JFR↓	Grade↑
Mistral-7B	60.21	25.62	3.98	47.50	19.58	4.87	59.05	39.52	3.97	54.79	23.34	4.34
Llama2-7B	46.67	19.79	4.85	32.73	18.18	5.54	62.86	26.67	3.89	45.49	20.68	4.88
Llama2-13B	65.67	21.66	3.71	55.33	16.67	4.42	48.10	20.48	4.78	57.28	19.50	4.25
Llama3-8B	39.79	12.09	5.19	33.75	17.28	5.51	46.25	19.18	4.83	38.67	15.60	5.25
Llama3.1-8B	55.83	21.46	4.36	36.39	12.78	5.60	47.62	12.86	5.00	47.52	16.77	4.91
Llama3.1-70B	41.56	14.22	5.34	25.00	11.88	6.42	38.33	10.00	5.55	34.10	12.38	5.83
Qwen2.5-7B	38.97	9.74	5.38	21.54	8.20	6.58	36.67	5.42	5.68	31.76	8.14	5.91
Qwen2.5-72B	<u>22.08</u>	<u>5.41</u>	<u>6.62</u>	10.42	1.46	7.67	<u>15.00</u>	3.75	7.28	<u>16.00</u>	3.50	<u>7.17</u>
GLM4-9B	52.73	16.36	4.76	51.67	14.00	4.93	50.00	15.24	5.00	51.67	15.24	4.88
Gemma2-9B	41.67	28.00	4.84	35.48	28.11	5.13	44.07	23.31	4.74	39.70	26.78	4.94
Gemini-Pro	30.21	11.87	5.98	19.39	5.76	6.59	32.86	5.72	5.78	27.25	8.62	6.14
Claude3.5-Sonnet	32.71	9.37	6.16	15.00	<u>2.33</u>	<u>7.41</u>	18.57	<u>3.33</u>	<u>7.31</u>	24.34	5.96	6.78
GPT-4o	14.05	4.34	6.78	<u>10.56</u>	4.93	7.26	10.48	1.41	7.62	12.02	<u>3.55</u>	7.21

GPT-4o đạt IMR thấp nhất (12.02%); Qwen2.5-72B (mã nguồn mở) bám sát. IMR là metric chủ đạo – Lin et al., Table 1.


Setup: 13 LLM = 10 open-source + 3 proprietary · suy luận zero-shot · temperature = 0 (tái lập được). Human và LLM tạo prototype cho IMR tương đương (Table 2).

Kịch bản khó nhất



IMR của 2 kịch bản khó nhất mỗi nhóm (Fig 4)

Vòng lặp hội tụ



IMR giảm dần & hội tụ qua các vòng probing (Fig 5)



Test Mode	Độ khó	GPT-4o IMR	Ảnh xạ RAG
[claim]	Khó nhất	23.1%	RAG tắt · baseline
[wisdom of crowds]	Trung bình	15.4%	evidence nhiều
[evidence]	Dễ nhất	10.6%	retrieval hoàn hảo · trần

Có bằng chứng giúp LLM fact-check chính xác hơn đáng kể (IMR giảm khoảng 2 lần). 3 mode = phổ chất lượng evidence: [claim] là **baseline** (chưa RAG), [evidence] là **trần trần** (RAG lý tưởng); RAG thực tế nằm giữa, tùy chất lượng retriever.



5

Thực nghiệm tái hiện

Nhóm chạy lại framework: baseline · vòng lặp adaptive · so sánh model

Phần 5



Phân vai 3 agent (qua API)

- **Optimizer:** `gemini-2.5-flash`
- **Judge:** `gemini-2.5-flash`
- **Target (model bị test):** thay đổi

Giữ nguyên logic paper

- Chỉ đổi backend LLM sang API
- Importance Sampling & taxonomy: nguyên vẹn

Quy mô mỗi lần chạy

- 3 seed (**Monte Carlo**) + 7 adaptive (**Importance Sampling**)
- Nhóm kịch bản: `complex_claim`
- Metric: **Grade 1–10, IMR** (% Grade ≤ 3)

Mục tiêu mid-term: chứng minh **tái hiện đúng cơ chế** của paper, không phải đạt SOTA.



Chạy target LLaMA-4-Scout: seed case chế độ `wisdom of crowds` bị điểm thấp (3/10).

Ở 7 case adaptive tiếp theo, Optimizer sinh **6/7 case đều** `wisdom of crowds` – đúng chế độ mô hình vừa làm kém. Đây chính là $q(x)$ tự dồn mật độ vào vùng $F_\alpha(x)$ thấp.

Tái hiện 2 tầng adaptive:

- **Tầng 1 (Prober):** sinh case khó hơn TRONG một kịch bản
- **Tầng 2 (Appraiser):** phân tích bad case → sinh **kịch bản MỚI** `deductive_causal_reasoning` (suy luận nhân quả nhiều bước) mà taxonomy gốc chưa có

Target model	Grade	IMR (% Grade ≤ 3)
LLaMA-4-Scout-17B	8.00	20%
Gemini 2.5 Pro	9.80	0%

Model mạnh (Gemini Pro) có **IMR thấp hơn hẳn**: khớp tinh thần Table 1 của paper (IMR là chỉ số phân biệt năng lực).

Model càng mạnh, Importance Sampling càng **khó đào ra điểm yếu** → cần nhiều vòng probing hơn để hội tụ (khớp Fig 5).



6

Từ Limitation → RAG

Đề xuất mở rộng của nhóm: cấp evidence qua retriever

Phần 6



1. Định kiến tiềm ẩn (bias)

Agent controller (GPT-4o) mang định kiến tri thức riêng.

VD: model có thể ưu tiên nguồn tiếng Anh, bỏ sót context văn hoá khác.

2. Tri thức tĩnh, không cập nhật động

Agent chỉ dùng tri thức đã học lúc train.

VD: claim về sự kiện mới sau training cutoff, model không có evidence để đối chiếu.


3. Thiếu cơ chế cải thiện mô hình

Framework chỉ kiểm định, chưa giúp model học lại.

VD: phát hiện LLaMA yếu ở "multi-step reasoning" nhưng không có bước fine-tune khắc phục.

Nhóm khai thác **hạn chế (2)**: paper tự đề xuất RAG, Table 3 cho thấy [evidence] dễ hơn [claim] rõ rệt, đủ cơ sở để thử nghiệm.

Paper tự nêu: "...incorporate advanced techniques such as Retrieval-Augmented Generation (RAG)..."



Giả thuyết: việc bổ sung evidence đưa trường hợp [claim] tiệm cận [evidence], kỳ vọng giảm IMR/JFR (trên cùng claim set và cùng target model).

Câu hỏi để ngỏ cho final-term: evidence của paper là **gold** (chuẩn, do người soạn). RAG thực tế lấy evidence **tự động** – nếu retrieval **kém liên quan** thì IMR có giảm không? Kết quả so sánh baseline vs RAG sẽ trình bày ở báo cáo cuối kỳ.



Đã làm được

- Hiểu & trình bày cơ chế FACT-AUDIT
- Tái hiện framework qua API
- Xác nhận Importance Sampling nhằm điểm yếu
- Tái hiện 2 tầng adaptive
- So sánh model: framework phân biệt mạnh/yếu

Hướng final-term

- Cắm retriever (RAG) trước target
- So sánh baseline vs RAG trên cùng claim set
- Phân tích ảnh hưởng của **chất lượng retrieval** lên IMR/JFR

Cốt lõi: từ **hiểu paper** → **tái hiện được** → **đề xuất mở rộng có cơ sở**.



Cảm ơn! · Q&A

Nhóm 15 · IT2040

Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn

Lin et al., **FACT-AUDIT**, ACL 2025 · arXiv 2502.17924

University of Information Technology, VNU-HCM (UIT)